

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М. В. ЛОМОНОСОВА

БИОЛОГИЧЕСКИЙ ФАКУЛЬТЕТ
Кафедра биоинженерии

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по теме

**Применение методов глубокого обучения для восстановления структуры
сахарофосфатного остова ДНК**

Выполнил:

Сидоров В. В.

Научный руководитель:

к.ф-м.н. Армеев Г. А.

Москва, 2026

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ.....	3
Актуальность.....	3
Цель.....	5
Задачи.....	5
ОБЗОР ЛИТЕРАТУРЫ.....	5
Структура ДНК как источник геометрических ограничений.....	5
Геометрическое описание оснований и локальные системы координат.....	8
Внутренние координаты остова ДНК.....	9
Псевдовращение сахарного кольца.....	10
Аналитическое восстановление декартовых координат.....	11
Обратное картирование как условная вероятностная задача.....	12
Диффузионные модели, оценивающие ГЛПВ.....	12
Трансформерные модели.....	13
МЕТОДЫ.....	14
Подготовка данных.....	14
Аналитическое геометрическое декодирование.....	18
Особенности диффузии.....	19
Архитектура модели.....	20
Обучение и генерация.....	23
Оценка качества.....	25
Оценка скорости работы модели.....	26
Исходный код.....	26
РЕЗУЛЬТАТЫ И ОБСУЖДЕНИЕ.....	27
Обучающая выборка.....	27
Оценка качества модели.....	27
Оценка скорости работы модели.....	38
Ограничения метода.....	38
ЗАКЛЮЧЕНИЕ.....	39
Выводы.....	39
Перспективы.....	40
СПИСОК ЛИТЕРАТУРЫ.....	40

ВВЕДЕНИЕ

Актуальность

Молекулярное моделирование ДНК связано с компромиссом между размером системы и уровнем детализации. Огрубленные модели, такие как Martini и SIRAH [1,2], позволяют рассчитывать более крупные системы и более длинные траектории, чем полноатомные модели, но после такого расчета часто требуется обратное картирование: восстановление атомной структуры для анализа водородных связей, локальной стереохимии, контактов с белками и энергии взаимодействий ДНК с ними.

Для двуцепочечной ДНК задача обратного картирования неоднородна: азотистые основания имеют сравнительно жесткую плоскую структуру, а их взаимное положение ограничено водородными связями и стэкинг-взаимодействиями. Поэтому положения оснований можно формально описывать через локальные системы координат; такой подход используется в 3DNA, DSSR и PyNAMod [3–5]. Сахарофосфатный остов устроен иначе: он содержит несколько вращаемых связей и пятичленное кольцо дезоксирибозы с выраженной конформационной подвижностью. Его положение не определяется однозначно геометрией оснований [5].

Эту неоднозначность можно нивелировать с помощью оптимизационных методов. В таком подходе сначала строится начальная полноатомная модель, а затем ее геометрия оптимизируется методами молекулярной механики, например при помощи GROMACS, AMBER, CHARMM [6–8]. Это позволяет получить корректную атомную структуру, но требует отдельной итерационной оптимизации для каждого фрагмента и поэтому занимает существенное время расчета. При обработке больших молекулярно-динамических траекторий или множества начальных моделей для уточнения по экспериментальным данным длительность таких расчетов становится существенным ограничением.

При фиксированном расположении азотистых оснований реализуются разные состояния дезоксирибозного кольца, разные значения гликозидного угла и разные комбинации торсионных углов фосфодиэфирной цепи. Поэтому условное распределение конформаций остова при заданной структуре оснований является мультимодальным. Покоординатная аппроксимация в декартовом пространстве не учитывает геометрическую структуру множества допустимых конформаций. Поэтому результат может оказаться вне этого множества: например, при наличии нескольких альтернативных состояний формальное среднее между ними способно нарушать молекулярные ограничения и не соответствовать ни одной физически реализуемой структуре.

В данной работе рассматривается другой подход: восстановление остова выполняется не итерационной оптимизацией, а прямой генерацией внутренних координат по известной геометрии оснований при помощи нейронной сети, предсказывающей градиент логарифма плотности вероятности (ГЛПВ) $s(x) = \nabla_x \log(p(x))$. Затем эти внутренние координаты переводятся в атомные координаты с помощью аналитического геометрического декодировщика. Такая схема сохраняет явные геометрические ограничения нуклеотида и при этом позволяет выполнять восстановление быстрее, чем при отдельной минимизации каждого фрагмента после обратного картирования статичными структурами остова.

Разработанная модель использует локальный структурный контекст нуклеотида: типы оснований, относительные положения и ориентации соседних нуклеотидов, спаренность оснований и положение целевого нуклеотида относительно концов цепи. Такой подход применим к обратному картированию огрубленных молекулярно-динамических траекторий и, потенциально, к построению начальных атомистических моделей по экспериментальным данным. В частности, в крио-ЭМ гибкие фрагменты молекулярных комплексов часто хуже определяются при усреднении плотности [9], что делает

восстановление подвижного остова ДНК по более надежно интерпретируемым основаниям практически полезной задачей.

Цель

Разработать метод условной генерации сахарофосфатного остова ДНК при известных признаках азотистых оснований.

Задачи

1. Подготовить данные для обучения модели.
2. Спроектировать и реализовать нейросетевую модель.
3. Обучить разработанную модель восстанавливать структуру остова ДНК, опираясь на структуру оснований.
4. Оценить качество обученной модели.

ОБЗОР ЛИТЕРАТУРЫ

Структура ДНК как источник геометрических ограничений

Структура двуцепочечной ДНК задается ковалентной цепью сахарофосфатного остова и набором азотистых оснований (рис. 1), которые образуют пары и укладываются в стопку. Эти две части молекулы различаются по характеру подвижности. Основания являются почти плоскими ароматическими фрагментами; в дуплексе их положение дополнительно ограничено водородными связями и стэкинг-взаимодействиями. Сахарофосфатный остов, напротив, содержит несколько последовательных вращаемых связей и пятичленное дезоксирибозное кольцо. Поэтому локальная геометрия остова имеет существенно больше конформационных степеней свободы [10].





Рисунок 1. Структура ДНК. Представлены две составляющие ДНК, важные в контексте данной работы: сахарофосфатный остов и азотистые основания. Адаптировано из [11].

Для восстановления структуры удобно разделить нуклеотид на две части: жесткое основание и подвижный остов. Локальная система координат основания задает начало отсчета, плоскость основания и направления осей, поэтому позволяет описывать соседние нуклеотиды без зависимости от глобального положения молекулы рис. 2. В такой постановке основание используется как условие для модели, а предсказываемой частью остаются внутренние координаты сахара, гликозидной связи и фосфодиэфирной цепи.

(a) A–U



(b) A+U




Рисунок 2. Антипараллельные и параллельные комбинации «сторон» пар оснований аденина (A) и урацила (U): (a) антипараллельная уотсон-криковская пара A–U с противоположно ориентированными сторонами (заштрихованная и незаштрихованная) и растяжением на $1,5 \text{ \AA}$, введенным для разделения двух базовых систем отсчёта оснований; (b) параллельная хугстиновская пара A+U со сторонами пары оснований одинаковой ориентации. Черные точки на основаниях обозначают атомы C1' присоединенных дезоксирибоз. Адаптировано из [3].

В задачах обратного картирования огрубленное представление нужно преобразовать в атомистическое, пригодное для анализа локальных контактов, стереохимии и энергетических вкладов. Для ДНК это преобразование естественно разбивается на две части. Положение оснований можно восстановить по большей части независимо от окружения, а для остова нужно выбрать значения внутренних координат, совместимые с соседними нуклеотидами и стандартной ковалентной геометрией. Поэтому далее основное внимание уделяется не декартовым координатам всех атомов, а параметрам, которые описывают подвижность остова.

Геометрическое описание оснований и локальные системы координат

Формальное описание нуклеиновых кислот обычно начинается с выделения оснований, пар оснований и локальных систем координат. Программа 3DNA вычисляет параметры пар оснований, шагов между парами, локальные оси и параметры спирали, а также поддерживает перестройку и визуализацию структур нуклеиновых кислот [3]. Программа анализа пространственной структуры РНК (Dissecting the Spatial Structure of RNA, DSSR [4]) систематизирует пары оснований, вторичную структуру, петли и пространственные мотивы нуклеиновых кислот. Библиотека PyNAMod использует близкую геометрическую идею для получения мезоскопического представления ДНК и извлечения параметров оснований из атомных структур [5].

Для данной работы эти инструменты важны как основание для выбора условного представления, а не как готовые алгоритмы восстановления остова. Они показывают, что геометрию оснований можно устойчиво описывать локальными системами координат и дискретными признаками: типом основания, относительным положением, ориентацией, спаренностью и положением в цепи. Поэтому в модели основание используется как геометрическое условие: положение и ориентация соседних оснований выражаются в системе отсчета целевого нуклеотида, что устраняет

произвольный выбор глобальной системы координат и оставляет на входе только локальный структурный контекст окна.

Внутренние координаты остова ДНК

Декартовы координаты избыточны для описания конформационной изменчивости ковалентной молекулы. Они напрямую задают положение атомов, но смешивают жесткие и подвижные компоненты геометрии. В нуклеиновых кислотах длины ковалентных связей и валентные углы сравнительно консервативны, тогда как основная конформационная изменчивость сосредоточена в торсионных углах. Для остова ДНК обычно рассматривают углы α , β , γ , δ , ϵ и ζ , а также гликозидный угол χ , задающий ориентацию основания относительно сахара (рис. 3).




Рисунок 3. Общепринятые обозначения торсионных углов сахарофосфатного остова ДНК. Адаптировано из [12].

Использование внутренних координат позволяет перенести часть химических ограничений из нейронной сети в аналитический геометрический декодировщик. Если модель предсказывает атомные координаты напрямую, она должна одновременно выучить распределение подвижных угловых координат, длины связей, валентные углы и хиральность. При предсказании внутренних координат сеть моделирует только те переменные, которые действительно обладают высокой изменчивостью. Остальные параметры могут быть заданы шаблонной геометрией или восстановлены из эталонных нуклеотидных фрагментов.

Псевдовращение сахарного кольца

Пятичленное фуранозное кольцо не является плоским. Его конформацию нельзя адекватно описать одной декартовой координатой или одной дискретной меткой. Классическая модель Альтоны и Сундаралингама описывает складчатость (puckering) дезоксирибозного кольца через фазу псевдовращения и амплитуду [13]. Фаза задает положение кольца на псевдовращательном цикле, а амплитуда характеризует выраженность выхода атомов из средней плоскости.

Для ДНК наиболее важны области C2'-эндо и C3'-эндо (рис. 4). C2'-эндо чаще ассоциирована с В-формой ДНК, C3'-эндо — с А-формой и РНК-подобными геометриями. Однако реальные структуры не исчерпываются этими двумя состояниями: возможны промежуточные и локально искаженные конформации. В качестве альтернативы декартовым координатам остов можно описывать внутренними координатами, то есть торсионными углами фосфодиэфирной цепи, гликозидным углом и параметрами конформации дезоксирибозного кольца. Такое представление задает именно подвижные степени свободы остова, тогда как длины связей и валентные углы могут фиксироваться геометрическим шаблоном или восстанавливаться аналитически.




Рисунок 4. Конформации дезоксирибозного кольца: C3'-эндо (слева) и C2'-эндо (справа) [14].

Аналитическое восстановление декартовых координат

После генерации внутренних координат нужно получить атомные координаты. В молекулярной геометрии это стандартная задача: если известны три ранее размещенных атома, длина связи, валентный угол и торсион, координата следующего атома определяется однозначно с точностью до выбранной хиральности. Для белков эффективное преобразование из торсионного пространства в декартово описано в методе естественного продолжения опорной системы координат (Natural Extension Reference Frame, NeRF) [15].

Для нуклеотидов задача сложнее из-за кольцевой структуры сахара и связи основания с сахаром. Тем не менее общий принцип сохраняется. Эталонные шаблоны нуклеотидов задают стабильные длины связей, валентные углы и относительное положение атомов основания. Предсказанные угловые внутренние координаты и параметры псевдовращения задают изменчивую часть геометрии. Затем геометрический декодировщик строит атомы сахара и фосфатной группы в локальной системе координат основания.

Такое разделение уменьшает размерность задачи и повышает химическую состоятельность результата. Нейронная сеть не обязана заново выучивать

геометрию, которая уже известна из химической структуры остова. Она моделирует распределение внутренних координат, а аналитический декодирующий переводит эти координаты в декартово пространство с заданными локальными ограничениями. Поэтому генерация через внутренние координаты ограничивает модель областью молекулярно осмысленных преобразований: сеть меняет конформацию остова через вращения, положение фосфата и складчатость сахара, а не через независимое смещение атомов в декартовом пространстве.

Обратное картирование как условная вероятностная задача

После выбора условного представления задача сводится к моделированию распределения внутренних координат остова при заданной локальной геометрии оснований. Такая постановка отличается от обычной регрессии. При близком положении оснований возможны разные состояния сахарного кольца, разные значения χ , γ и δ , а также разные положения фосфатной группы. Если обучать модель предсказывать единственный набор координат, она будет стремиться к усредненному решению; при мультимодальном распределении такое решение может не соответствовать физически наблюдаемой конформации.

Генеративная модель вместо этого строит выборку из условного распределения. Для одного и того же контекста оснований она может дать несколько допустимых вариантов остова, различающихся внутренними координатами. В данной работе для этого используется диффузионная модель в пространстве угловых внутренних координат: сеть не предсказывает атомные координаты напрямую, а оценивает ГЛПВ зашумленного распределения внутренних координат.

Диффузионные модели, оценивающие ГЛПВ

Диффузионные генеративные модели строят распределение данных через прямой процесс зашумления и обратный процесс удаления шума. В вероятностных диффузионных моделях удаления шума (Denoising Diffusion

Probabilistic Models, DDPM) прямой процесс постепенно переводит данные в нормальное распределение, а обратный процесс аппроксимируется нейронной сетью [16]. Эта парадигма стала одним из основных подходов к генеративному моделированию сложных распределений.

Более общая формулировка диффузионных моделей описывает обратный процесс через градиент логарифма плотности зашумленных данных. Этот градиент показывает, в каком направлении нужно сместить зашумленный образец, чтобы приблизить его к области большей вероятности. Метод согласования ГЛПВ был предложен для обучения ненормированных статистических моделей без вычисления нормировочной константы [17]. Работа Song и соавторов связывает такой подход со стохастическими дифференциальными уравнениями и показывает, что прямой и обратный процессы можно рассматривать в непрерывном времени [18].

Для восстановления остова такая постановка естественна. Модель не должна выбирать заранее число конформационных кластеров и не должна сводить распределение к одной точке. Она обучается локально: для заданного уровня шума сеть предсказывает направление, в котором зашумленный образец должен сместиться к области большей плотности данных. В данной задаче это направление задается в пространстве угловых внутренних координат и логарифма амплитуды сахарной складчатости. Поэтому обратная диффузия действует не на атомы как на независимые точки, а на переменные, которые уже имеют химический смысл. Это делает выборку геометрически более согласованной: любой вариант после декодирования проходит через фиксированную ковалентную схему нуклеотида, а вариативность остается в тех степенях свободы, где она физически ожидаема. Угловые компоненты требуют завернутого ГЛПВ, вещественная компонента может моделироваться обычным гауссовым ГЛПВ.

Трансформерные модели

Конформация целевого нуклеотида зависит не только от его типа. На нее влияют контекстные нуклеотиды, ориентации оснований в окне, наличие

комплементарной пары, локальное направление цепи и положение относительно 5'- или 3'-конца. Поэтому условная модель должна получать не одиночный нуклеотид, а структурное окно.

Для обработки такого окна используется трансформер [19]. Его основной механизм, самовнимание, вычисляет взаимодействия между элементами входной последовательности через обучаемые веса внимания. В исходной работе эта архитектура была предложена для обработки текста, но ее принцип не зависит от природы элементов последовательности. В контексте ДНК элементами являются нуклеотиды окна, а признаками служат их типы, относительные положения, ориентации, признаки спаренности и уровень шума.

Преимущество такого представления состоит в том, что локальная геометрия оснований кодируется напрямую через относительные системы отсчета, а не через атомный граф. Трансформер получает компактное описание контекста и предсказывает ГЛПВ только для целевого нуклеотида. Химическая геометрия затем восстанавливается не механизмом внимания, а аналитическим декодировщиком.

МЕТОДЫ

Подготовка данных

Исходные структуры ДНК загружались из базы RCSB PDB в формате mmCIF (рис. 5). В выборку включались структуры, удовлетворяющие следующим условиям: метод определения структуры — рентгеноструктурный анализ или электронная микроскопия; полимер содержит ДНК; длина ДНК не менее трех нуклеотидов; разрешение не хуже 3 Å. Структуры прочитаны с помощью PyNAMod. Для каждой структуры выделялись цепи ДНК, нуклеотиды, типы оснований, пары оснований и локальные системы координат оснований [3]. Структуры с ошибками прочтения или неполными данными пропускались.




Рисунок 5. Основные этапы подготовки обучающей выборки. Из RCSB PDB загружались структуры в формате mmCIF, удовлетворяющие заданным фильтрам: метод определения структуры — рентгеноструктурный анализ или

крио-ЭМ, наличие ДНК и разрешение не хуже 3 Å. После чтения структур для каждой цепи ДНК формировались объекты данных в виде окон из последовательных нуклеотидов. В каждом окне сохранялись локальные системы отсчета оснований, дискретные признаки нуклеотидов, угловые внутренние координаты остова, амплитуда складчатости сахарного кольца и маска наблюдаемости внутренних координат. Полученные окна затем разделялись на обучающую, валидационную и тестовую выборки.

Для каждой корректной цепи строились перекрывающиеся окна длиной 3 нуклеотида (рис. 6). Окна с разрывами цепи исключались. Для каждого нуклеотида в окне сохранялись координаты и ориентация основания, тип основания, признак наличия пары, класс положения в цепи, внутренние координаты и координаты атомов остова. Для парного нуклеотида, если он был найден, сохранялись его координаты и ориентация; при отсутствии пары соответствующие признаки заполнялись нулями и сопровождалась бинарным признаком отсутствия пары.




Рисунок 6. Три последовательно идущих нуклеотида. Показаны только локальные системы отсчета оснований (отмечены стрелками); атомы оснований скрыты для наглядности.

Целевым нуклеотидом обычно был внутренний нуклеотид окна. Для окон, касающихся конца цепи, дополнительно создавались примеры, где целевым становился крайний нуклеотид. Это нужно, чтобы модель умела генерировать крайние остовы цепей, обладающие уникальной геометрией в связи с отсутствием одного из контекстных нуклеотидов. При построении обучающего загрузчика данных применялся взвешенный выборщик: доля примеров с целевым нуклеотидом на краю цепи задавалась отдельным гиперпараметром, чтобы такие случаи не терялись на фоне обычных окон.

Перед подачей в модель геометрические признаки окна переводились в локальную систему координат целевого основания. Координаты контекстных оснований и парных оснований выражались относительно начала и ориентации системы отсчета целевого нуклеотида. В результате модель получала относительное описание локальной геометрии, не зависящее от глобального положения и ориентации молекулы.

Разделение на обучающую, валидационную и тестовую части проводилось на уровне групп PDB-записей, а не отдельных окон. Группой считали набор структур, связанных общими метаданными депонирования в RCSB PDB. Все окна, полученные из структур одной группы, попадали только в одну часть выборки. Если для структуры такая связь не была указана, она считалась отдельной группой. Это снижало риск утечки близких экспериментальных структур между обучением, валидацией и тестированием. Разделение по последовательности не использовалось, потому что одинаковая последовательность ДНК может иметь разные конформации, включая А-, В- и Z-формы.

Аналитическое геометрическое декодирование

Для каждого нуклеотида вычислялся набор внутренних координат: мостиковая фаза фосфата, γ , δ , χ , η_r , фаза псевдовращения дезоксирибозного кольца и амплитуда складчатости дезоксирибозного кольца τ_m . Угол γ соответствует $O5'-C5'-C4'-C3'$ и используется при построении $O5'$. Угол δ соответствует $C5'-C4'-C3'-O3'$ и используется при построении $O3'$. Угол χ задает взаимное положение основания и сахарного кольца. Мостиковая фаза задает положение фосфора Р на окружности допустимых положений между $O3'$ предыдущего и $O5'$ текущего нуклеотида. Стандартные углы α , β , ϵ и ζ в текущей реализации не предсказывались как отдельные целевые переменные.

Для задания положения немостиковых атомов кислорода фосфатной группы был введен дополнительный угол η_r , соответствующий углу $C5'-O5'-P-OP1$. Этот угол не входит в стандартный набор торсионных углов остова, используемый в программах анализа нуклеиновых кислот, таких как 3DNA и DSSR, поскольку $OP1$ и $OP2$ обычно рассматриваются как боковые атомы фосфата. В данной работе их координаты требовались для получения полноатомной структуры, поэтому положение $OP1$ задавалось через η_r . Положение $OP2$ не предсказывалось отдельным углом, а восстанавливалось из шаблонной тетраэдрической геометрии фосфатной группы: использовались длина связи $P-OP2$, валентные углы $O5'-P-OP2$ и $OP1-P-OP2$, а также шаблонное угловое смещение $OP2$ относительно $OP1$.

Часть угловых внутренних координат может быть не наблюдаема. Например, для 5'-концевого нуклеотида отсутствует предыдущий $O3'$, поэтому невозможно вычислить мостиковую фазу фосфата. η_r нельзя вычислить при отсутствии $OP1$, а фазу псевдовращения и τ_m — при неполном сахарном кольце. Поэтому вместе со значениями внутренних координат сохранялась булева маска наблюдаемости. Эта маска использовалась при обучении, чтобы не штрафовать модель за компоненты, которые невозможно вычислить из структуры.

Для описания дезоксирибозного кольца сначала вычислялись пять эндоциклических торсионных углов: $C1'-C2'-C3'-C4'$, $C2'-C3'-C4'-O4'$,

$C3'-C4'-O4'-C1'$, $C4'-O4'-C1'-C2'$ и $O4'-C1'-C2'-C3'$. По ним определялись фаза псевдовращения и амплитуда τ_m . Для численной стабильности амплитуда передавалась в модель в логарифмической форме.

Целевой скрытый вектор имел размерность 7: 6 периодических угловых компонент и 1 вещественная компонента $\log(\tau_m)$. Угловые компоненты включали мостиковую фазу фосфата, γ , δ , χ , фазу псевдовращения и η_p . Все угловые значения приводились к интервалу $(-\pi, \pi]$. Такое представление соответствует топологии данных: угловые компоненты живут на окружности, а амплитуда складчатости дезоксирибозного кольца — на положительной вещественной полуоси, переведенной в логарифмическую шкалу.

Обратное преобразование выполнял аналитический геометрический декодировщик. Он использовал шаблонные геометрические параметры канонических нуклеотидов А, С, G и Т: длины связей, валентные углы, относительное положение атомов основания и опорные параметры дезоксирибозного кольца. Сначала по фазе псевдовращения, τ_m и χ строилось дезоксирибозное кольцо. Затем по δ достраивался $O3'$, по γ — $O5'$, а $C5'$ задавался шаблонной геометрией относительно сахарного кольца. При наличии предыдущего $O3'$ фосфор Р размещался по мостиковой фазе между $O3'$ предыдущего и $O5'$ текущего нуклеотида. Немостиковые атомы $OP1$ и $OP2$ достраивались по η_p и шаблонной геометрии фосфатной группы.

Такое разделение переносит фиксированные химические ограничения из нейронной сети в декодировщик. Длины связей, валентные углы и базовая топология нуклеотида задаются шаблоном, а модель отвечает только за переменные с высокой конформационной изменчивостью. Это уменьшает размерность предсказания и снижает риск получения геометрии с нарушенной ковалентной структурой.

Особенности диффузии

Для моделирования распределения внутренних координат использовалась условная диффузионная модель на основе ГЛПВ. Прямой процесс зашумления

применялся к скрытому вектору целевого нуклеотида: угловые компоненты зашумлялись на окружности, а компонент $\log(\tau_m)$ — в евклидовом пространстве.

При обучении уровень шума задавался вещественным параметром t из интервала $[0, 1]$, который выбирался случайно для каждого объекта. При генерации то же расписание дискретизировалось в траекторию из заданного гиперпараметром числа шагов, а обратный процесс выполнялся ODE-сэмплером (выборщиком на основе обыкновенного дифференциального уравнения). Для углов θ и для $\log(\tau_m)$ использовались отдельные экспоненциальные расписания стандартного отклонения:

$$\sigma_{\theta}(t) = \sigma_{\theta, \min}^{(1-t)} \sigma_{\theta, \max}^{(t)}$$

$$\sigma_{\tau_m}(t) = \sigma_{\tau_m, \min}^{(1-t)} \sigma_{\tau_m, \max}^{(t)}$$

Для угловых компонент применялось завернутое нормальное распределение. Если θ_0 — исходный угол, а $\sigma_{\theta(t)}$ — уровень шума, то зашумленный угол θ_t получался добавлением гауссова шума с последующим приведением результата к интервалу $(-\pi, \pi]$. Целевой ГЛПВ для углов вычислялся как производная логарифма плотности завернутого нормального распределения по θ_t . Для компоненты $\log(\tau_m)$ использовался обычный гауссов ГЛПВ:

$$s(y_t, y_0, \sigma) = -\frac{(y_t - y_0)^2}{\sigma^2}$$

Модель обучалась предсказывать ГЛПВ зашумленного скрытого вектора. Для стабилизации вклада разных уровней шума применялось взвешивание ошибки на σ^2 .

Архитектура модели

ГЛПВ предсказывался трансформером (рис. 7). На вход подавалась последовательность из трех нуклеотидов окна. Для каждого нуклеотида статические признаки включали тип основания, класс положения в цепи (5'-крайний/3'-крайний/внутренний), признак целевого нуклеотида, признак

наличия пары, координаты начала локальной системы отсчета основания и матрицу ее ориентации, записанную как 9 чисел. Координаты и ориентации задавались относительно локальной системы отсчета целевого основания. Для найденного парного основания использовались такие же геометрические признаки: относительное положение и матрица ориентации; при отсутствии пары эти компоненты заполнялись нулями.




Рисунок 7. Архитектура модели для предсказания ГЛПВ. На вход модели подается окно из трех нуклеотидов, описанное признаками оснований,

относительными локальными системами отсчета, метками нуклеотидов, зашумленным скрытым вектором внутренних координат, маской наблюдаемости, синусоидальным представлением уровня шума и вектором самообуславливания. Сначала входные признаки каждого нуклеотида проецируются многослойным перцептроном в скрытое пространство. Затем трансформер с тремя слоями и восемью головами внимания обрабатывает структурный контекст окна. Выходная голова предсказывает ГЛПВ для скрытого вектора целевого нуклеотида. При генерации этот ГЛПВ используется на шагах обратной диффузии для перехода от зашумленного состояния к восстановленным внутренним координатам остова.

Диффузионные признаки добавлялись только к целевому нуклеотиду. Они включали зашумленный скрытый вектор текущего шага, синусоидальное представление уровня шума и вектор самообуславливания, то есть оценку исходного скрытого вектора, полученную на предыдущем шаге генерации [20]. Если такой оценки еще не было, вектор самообуславливания заполнялся нулями. Для контекстных нуклеотидов все диффузионные компоненты также заполнялись нулями. Поэтому модель получала структурный контекст всего окна, но предсказывала ГЛПВ только для целевого нуклеотида.

Нейронная сеть состояла из входного многослойного перцептрона, 3 слоев трансформера и линейного выходного слоя. Скрытая размерность составляла 256, число голов внимания — 8. Выходной слой возвращал семимерный вектор, соответствующий ГЛПВ 6 угловых компонент и $\log(\tau_m)$. Из всех выходов сети использовался только выход целевого нуклеотида.

Обучение и генерация

Модель обучалась 6 ч на сервере с 2 видеокартами NVIDIA RTX A5000, 64 ГБ оперативной памяти и 4 процессорными ядрами (скорость обучения почти линейно зависит от количества видеокарт, т. е. можно обучать быстрее). Оптимизация проводилась алгоритмом AdamW [21] с темпом обучения 10^{-3} . Градиенты обрезались по норме до 1. Для повышения устойчивости использовалось стохастическое усреднение весов, начиная с поздних эпох

обучения. Вычисления проводились с точностью TF32. Применялась L_2 -регуляризация весов [21].

В каждой обучающей итерации для каждого окна выбирался случайный уровень шума t . Внутренние координаты целевого нуклеотида зашумлялись согласно расписаниям $\sigma_{\theta(t)}$ и $\sigma_{\tau(t)}$. После этого модель получала структурный контекст окна, зашумленный скрытый вектор и логарифм уровня шума. Целевой функцией была среднеквадратичная ошибка между предсказанным и аналитически вычисленным ГЛПВ. Ошибка по углам и ошибка по $\log(\tau_m)$ суммировались, причем вклад $\log(\tau_m)$ задавался отдельным гиперпараметром.

$$L_{\text{тренир.}} = L_{\text{ГЛПВ, } \theta} + \lambda_{\tau} L_{\text{ГЛПВ, } \log(\tau_m)} + \lambda_{\text{замык.}} L_{\text{замык.}}$$

Для дополнительного контроля геометрии использовалась регуляризация по локальному межнуклеотидному соединению (замыкание). По предсказанному ГЛПВ строилась оценка исходного скрытого вектора, затем она декодировалась в атомные координаты. Штраф учитывал отклонения длин связей, валентных и торсионных углов на границе контекстных нуклеотидов от шаблонных значений. Этот член не заменял основную цель согласования ГЛПВ, а только геометрически штрафовал плохие реконструкции.

$$L_{\text{замык.}} = \omega_{\text{связи}} L_{\text{связи}} + \omega_{\text{углы}} L_{\text{углы}} + \omega_{\text{мост. фаза}} L_{\text{мост. фаза}}$$

При валидации, тестировании и применении выполнялся полный обратный процесс. Начальное состояние задавалось случайными углами, равномерно распределенными на интервале $(-\pi, \pi]$, и случайным значением $\log(\tau_m)$. Далее использовалось расписание уровня шума от максимального к минимальному. На каждом шаге модель предсказывала ГЛПВ текущего состояния, после чего скрытый вектор обновлялся ODE-сэмплером. В отличие от стохастического сэмплера, на шагах обратного процесса не добавлялся дополнительный шум; стохастичность генерации задавалась случайным начальным состоянием. Угловые компоненты после каждого шага приводились к интервалу $(-\pi, \pi]$. Число шагов обратной диффузии составляло 200.

После завершения обратного процесса модель возвращала угловые внутренние координаты и амплитуду τ_m . Эти значения передавались в геометрический декодировщик. Для всей цепи предсказания из перекрывающихся окон объединялись по нуклеотидам. По умолчанию атомы 5'-концевого фосфата P, OP1 и OP2 не генерировались; при необходимости их генерация включалась отдельным параметром.

Оценка качества

Основной метрикой качества было среднеквадратичное отклонение атомных координат (СКО) между восстановленным остовом и остовом экспериментальной структуры. Метрика вычислялась в локальной системе координат целевого основания, чтобы устранить влияние глобального положения молекулы. При вычислении СКО учитывались атомы остова целевого нуклеотида. Для симметричных атомов OP1 и OP2 использовалось минимальное расстояние по двум возможным соответствиям, поскольку их имена могут быть переставлены без изменения физического смысла фосфатной группы.

СКО отдельно агрегировался по 3 категориям: для всех нуклеотидов в среднем, для внутренних нуклеотидов и для нуклеотидов на концах цепи.

Для сравнения качества модели использовались два контрольных метода. Первый метод представлял собой шаблонную реконструкцию: средние внутренние координаты вычислялись по обучающей выборке, затем подавались в геометрический декодировщик, после чего вычислялось СКО восстановленного остова. Второй метод использовал метод k ближайших соседей (k-nearest neighbors, kNN). Для каждого тестового окна подбирался наиболее похожий фрагмент из тренировочной выборки, а его локальные координаты остова использовались как предсказание. Чтобы избежать утечки близких структур, из кандидатов исключались окна из того же идентификатора PDB, той же группы депонирования и структур с идентичной последовательностью ДНК. Метод kNN запускался с разными наборами признаков: только типы оснований, только положения локальных систем

отсчета, только их ориентации, положения и ориентации вместе, признаки комплементарных нуклеотидов и полный статический набор признаков.

Для оценки разброса между независимыми генерациями на одних и тех же входных данных для части окон тестового набора выполнялось по 10 запусков модели. Затем между полученными вариантами остова вычислялся попарный СКО. Поскольку используется ODE-сэмплер, на шагах обратного процесса не добавляется новый шум — различия между запусками возникают из-за разных случайных начальных состояний.

Оценка скорости работы модели

Для сравнения времени работы модель сопоставлялась с геометрической минимизацией в PHENIX. Из тестового набора выбиралось 30 структур со стандартной химией ДНК, пригодных для чтения обоими методами. Для PHENIX остовы цепей заменялись шаблонными (геометрия остова для ДНК в В-форме), а затем запускалась геометрическая минимизация остова с 500 итерациями и 5 макроциклами. Для нейронной сети остовы цепей удалялись и измерялось полное время восстановления структуры: чтение входного файла, генерация остова, сборка выходной модели и запись результата. Вычисления нейронной сети проводились на видеокарте NVIDIA RTX A5000 с 15 шагами ODE-сэмплера (качество не ухудшалось относительно большого количества шагов на тренировке), вычисления PHENIX — на 4 процессорных ядрах.

Исходный код

Весь код для подготовки данных, тренировки и использования модели написан на Python 3 (основные библиотеки: PyNAMod, PyTorch, Lightning). Исходный код и веса модели находятся в публичном доступе в GitHub репозитории: <https://github.com/Eclippter/base2backbone>. Список структур, использованных для обучающей выборки зафиксирован в "thesis_2026-05-17.json". Основной интерфейс программы принимает структуру ДНК без остова и восстанавливает атомы остова. На входе и выходе поддерживаются форматы PDB и mmCIF. Имеется поддержка траекторий.

РЕЗУЛЬТАТЫ И ОБСУЖДЕНИЕ

Обучающая выборка

Из RCSB PDB было загружено 8055 структур, удовлетворявших первичным фильтрам. PyNAMod корректно прочитал 6170 из них; после разбиения корректных цепей на окна длиной три нуклеотида было получено 432 247 окна. Оставшиеся структуры не попали в набор данных из-за ограничений обработки или фильтрации. Основной причиной было отсутствие найденной комплементарной пары хотя бы для одного нуклеотида структуры: по этой причине было исключено 1198 структур. Реже встречались структуры с отсутствующими нуклеотидами (138 структур), нестандартными мономерами (64 структуры), цепями короче трех нуклеотидов (5 структур) и прочими единичными особенностями.

Всего было найдено 7187 нестандартных мономеров, что составляет 1,66 % от всех мономеров в обработанном наборе. Наиболее частыми кодами химических компонентов RCSB PDB среди нестандартных мономеров были: 5CM — 5-метил-2'-дезоксцитидин-5'-монофосфат, 593 случая (8,25 % от всех нестандартных мономеров); DN — неизвестный 2'-дезоксинуклеотид, 346 случаев (4,81 %); DOC — 2',3'-дидезоксцитидин-5'-монофосфат, 298 случаев (4,15 %); BRU — 5-бром-2'-дезоксгуанидин-5'-монофосфат, 264 случая (3,67 %); 8OG — 8-оксо-2'-дезоксигуанозин-5'-монофосфат, 252 случая (3,51 %).

Эти результаты показывают, что основной резерв увеличения выборки связан не с поддержкой отдельных модифицированных нуклеотидов, а с чтением структур без найденной комплементарной цепи. Несмотря на это, поддержка нестандартных мономеров расширила бы область применения метода на модифицированные и поврежденные нуклеотиды.

Оценка качества модели


Итоговая конфигурация модели, выбранная по среднеквадратичному отклонению остова на валидационной выборке, имела следующие параметры:

- Размерность скрытого пространства: 256.


- Темп обучения: 10^{-3} .
- Коэффициент L_2 -регуляризации: 10^{-2} .
- Размер пакета: 50000.
- Вес окон с крайними нуклеотидами: 0,3.
- 200 эпох обучения.
- Старт стохастического усреднения весов на эпохе 100.
- 200 шагов диффузии.
- Уровень шума для угловых компонент:
 - Минимальный: $0,01\pi$.
 - Максимальный: π .
- Уровень шума для компоненты $\log(\tau_m)$:
 - Минимальный: 0,01.
 - Максимальный: 1,5.
- Вес ошибки по каналу $\log(\tau_m)$: 1.
- Вес дополнительного штрафа за геометрическое замыкание сахарофосфатного остова:
 - Общий: 10^{-3} .
 - Отдельные веса компонент функции потерь замыкания сахарного кольца:
 - Атомные связи: 1.
 - Валентные углы: 0,3.
 - Торсионные углы: 1.

На рис. 7 показаны динамика функции потерь, среднеквадратичное отклонение на валидационной выборке и итоговая ошибка на тестовой выборке. После начала стохастического усреднения весов валидационная ошибка стабилизируется. Ошибка для крайних нуклеотидов выше, чем для внутренних, что ожидаемо: на концах цепи доступен менее полный структурный контекст.

а)



б)



в)




Рисунок 8. (а) Функция потерь во время тренировки модели (безразмерная); (б) СКО во время валидации модели; (в) СКО модели на тестовом датасете.


Увеличение размера окна до 5 и 7 не привело к улучшению метрик. По-видимому, конформация остова зависит только от локальных геометрических признаков.

Варьирование порога разрешения для создания набора данных (2,5; 3; 3,5; 4 Å) также не привело к изменению метрик. Это показывает, что в выбранном диапазоне разрешение экспериментальных структур не является основным фактором, ограничивающим качество модели. Вероятно, структуры с худшим разрешением не вносят выраженного систематического смещения в целевые координаты остова, либо их вклад перекрывается другими источниками ошибки, связанными с неоднозначностью восстановления остова по структуре оснований.


На рис. 9 приведен пример восстановленного моделью сахарофосфатного остова. В показанном фрагменте сахарное кольцо воспроизводится точнее, чем фосфатная группа. Такая картина согласуется с устройством геометрического декодировщика: положение фосфатной группы зависит от нескольких

последовательно предсказанных угловых координат, поэтому ошибки в этой области накапливаются сильнее.

а)



б)



в)





Рисунок 9. Пример сгенерированного моделью сахарофосфатного остова: (а) остов внутреннего нуклеотида отдельного окна; (б) остов крайнего нуклеотида отдельного окна; (в) остов целой структуры (сгенерированный слева и исходный справа). Стрелками на (а) и (б) отмечены локальные системы отсчета соответствующих нуклеотидов.

На тестовой выборке также был посчитан СКО после декодирования внутренних координат истинных атомов остова. Разложение ошибки по атомам подтверждает, что наибольший вклад в отклонение дают атомы фосфатной группы (рис. 10).

a)



б)




Рисунок 10. (а) СКО модели на тестовом наборе данных для каждого атома сахарофосфатного остова по отдельности; (б) вклад СКО соответствующих атомов в общий СКО остова.

Для оценки вклада геометрического декодировщика отдельно было проведено контрольное декодирование с истинными внутренними координатами, извлеченными из экспериментальной структуры. Средний СКО такого восстановления составил 0,3 Å. При замене истинных внутренних координат на предсказанные СКО между двумя результатами одного и того же декодировщика составил 1,2 Å, а полный СКО предсказанной структуры относительно экспериментальной структуры — 1,3 Å. Близость двух последних значений показывает, что основная часть дополнительной ошибки полной модели связана с предсказанием внутренних координат. При этом ненулевая ошибка контрольного декодирования показывает, что выбранное внутреннее представление и шаблонная геометрия декодировщика также вносят заметный вклад в итоговое отклонение.

Сравнение с контрольными методами показывает, что одиночная генерация модели уступает лучшему варианту kNN (табл. 1) и остается на уровне с шаблонной реконструкцией. Это может быть связано с тем, что нейронная сеть умеет генерировать правдоподобные конформации, но ей не хватает критерия выбора одной верной.

Таблица 1. Сравнение качества модели с контрольными методами: средним шаблоном, вариантами метода k ближайших соседей (kNN) и PHENIX на тестовом наборе данных. (а) СКО координат атомов, Å; (б) химическая корректность. Жирным выделением отмечены лучшие значения в соответствующих столбцах.

а)

	Среднее	Медиана	90-й перцентиль	Среднее (внутренние нуклеотиды)	Среднее (крайние нуклеотиды)

Нейросеть	1,0	0,9	1,8	0,9	1,3
Шаблонная реконстр.	1,0	0,9	1,5	1,0	1,3
kNN (только основания)	1,2	1,0	2,0	1,1	1,8
kNN (только начала систем отсчета)	0,8	0,7	1,4	0,7	1,1
kNN (только направления систем отсчета)	0,9	0,8	1,9	0,9	1,3
kNN (только системы отсчета)	0,7	0,5	1,3	0,6	1,0
kNN (системы отсчета и типы оснований)	0,7	0,5	1,3	0,7	1,1
kNN (системы отсчета комплем-ых нукл-ов)	1,0	0,8	1,9	0,9	1,3
kNN (все признаки)	0,7	0,6	1,5	0,7	1,1
PHENIX	1,1	0,9	2,2	1,1	1,6

б)

	Средний СКО длин связей (Å)	Средний СКО углов (°)	Среднее число стерических конфликтов на 1000 атомов
Нейросеть	0,10	14,6	70

Шаблонная реконструкция	0,04	9,9	31
kNN (основания)	0,12	9,0	65
kNN (начала систем отсчета)	0,10	7,1	60
kNN (направления систем отсчета)	0,09	6,2	56
kNN (системы отсчета)	0,08	5,8	42
kNN (системы отсчета и типы оснований)	0,09	6,1	45
kNN (системы отсчета комплементарных нуклеотидов)	0,11	8,1	62
kNN (все признаки)	0,09	6,6	48
PHENIX	0,01	0,6	4

Лучший результат среди вариантов kNN был получен при использовании локальных систем отсчета оснований. Это показывает, что относительные положения и ориентации соседних оснований несут значимую информацию о конформации остова. Полный набор признаков не дал улучшения: для метода kNN лишние или слабоинформативные признаки могут исказить метрику расстояния и ухудшать выбор ближайшего фрагмента.

Это сравнение имеет одно техническое ограничение. Метод kNN переносит локальные координаты остова из обучающего фрагмента напрямую. Он не преобразует внутренние координаты через аналитический декодировщик, поэтому его ошибка не ограничена ошибкой контрольного декодирования с истинными внутренними координатами. По этой причине результаты kNN и нейросети сравнивают качество восстановления конечных атомных координат,

но не являются прямым сравнением двух способов предсказания внутренних координат.

Дополнительно была проведена оценка выбора лучшего из K независимых генераций (рис. 11). Для каждого объекта выполнялось K запусков модели, после чего выбирался вариант с минимальным СКО относительно экспериментальной структуры. Такой режим использует истинные координаты и поэтому не является практической процедурой применения модели, но показывает, содержатся ли в порождаемом распределении близкие к эксперименту варианты. В этом режиме при $K=4$ нейросеть становится сопоставимой с лучшими вариантами kNN (табл. 1): средний СКО составил 0,7 Å, медианный СКО — 0,6 Å, 90-й перцентиль — 1,2 Å. Средний СКО для внутренних нуклеотидов составил 0,7 Å, для крайних — 0,9 Å. Значительное улучшение по сравнению с одиночной генерацией подтверждает гипотезу, что модель часто порождает качественные конформации остова, но без дополнительного критерия не всегда выбирает верную.




Рисунок 11. Зависимость среднего СКО остова на лучшем запуске от числа запусков K .

Следовательно, для использования мультимодальной генерации нужен внешний критерий выбора. Если истинная структура неизвестна, лучший вариант можно выбирать не по СКО, а по дополнительной геометрической оценке, энергетическому критерию, проверке стерических столкновений или короткой последующей минимизации.

СКО геометрического декодировщика на истинных данных составил Å. Из совокупности этого и предыдущего результата можно сделать вывод, что ошибка самой модели на лучшей генерации

Оценка скорости работы модели

Сравнение с PHENIX показало преимущество нейросетевого восстановления по времени работы. Среднее время работы в пересчете на 1 структуру у PHENIX составило 17 с, а у нейросети — 1,5 с. Таким образом, полный цикл восстановления остова оказался примерно в 11 раз быстрее.

Это ускорение относится к полному циклу обработки на конкретном наборе структур и конкретном оборудовании. Оно не является универсальной константой, поскольку время зависит от размера структуры, числа цепей, числа шагов ODE-сэмплера и накладных расходов на запуск программ. Тем не менее результат показывает, что для массовой обработки структур или кадров молекулярной динамики нейросетевое восстановление может быть существенно быстрее итерационной минимизации.

Ограничения метода

Во-первых, модель обучалась только на канонических нуклеотидах А, С, G и T. Нестандартные, модифицированные и поврежденные нуклеотиды исключались из обучающей выборки. Это ограничивает применимость метода к структурам с химическими модификациями ДНК. Для расширения метода на такие случаи потребуются дополнительные шаблоны нуклеотидов, адаптация набора внутренних координат и пополнение обучающей выборки соответствующими примерами.

Кроме того, генерация отдельных нуклеотидов из перекрывающихся окон не полностью эквивалентна совместной генерации всей цепи. Для согласования соседних нуклеотидов используются геометрический штраф и аналитическое восстановление межнуклеотидных соединений, однако модель не оптимизирует всю цепь как единую молекулярную систему. Поэтому ошибки могут накапливаться в областях фосфатных групп и на концах цепей, где доступный структурный контекст меньше (рис. 10).

Наконец, метод не включает явную энергетическую минимизацию, проверку стерических столкновений и учет силового поля. Полученная структура является результатом генерации внутренних координат и аналитического декодирования, а не минимумом молекулярно-механической энергии. Поэтому для задач, требующих строгой физико-химической релаксации, восстановленный остов может использоваться как начальная структура для последующей короткой геометрической оптимизации.

ЗАКЛЮЧЕНИЕ

Выводы

1. Подготовленный набор данных достаточен для обучения модели, а его применимость ограничена каноническими нуклеотидами и структурами двуцепочечной ДНК.
2. Разработанная модель позволяет генерировать геометрию остова ДНК, а ошибка модели во многом объясняется трудностью выбора верной моды из мультимодального распределения координат.
3. Координат оснований достаточно для восстановления геометрии остова ДНК, однако не достаточно для воспроизведения изначальных координат атомов в экспериментальных структурах.
4. Среднеквадратичное отклонение координат атомов от изначальной структуры не следует использовать для оценки качества генерации остова ДНК, поскольку эта метрика не отражает геометрическую корректность модели. Нужно сравнивать эталонные и восстановленные длины связей и валентные углы.

Перспективы

Дальнейшая работа должна быть направлена прежде всего на снижение ошибки в области фосфатной группы, поскольку именно фосфатные атомы дают основной вклад в СКО. Для этого можно перейти от независимой генерации нуклеотидов в перекрывающихся окнах к совместному восстановлению более длинного фрагмента цепи, усилить учет межнуклеотидного соединения и добавить отбор нескольких независимых вариантов по геометрическому или энергетическому критерию.

Практическое применение метода возможно как быстрый этап обратного картирования после огрубленного молекулярно-динамического моделирования ДНК. Для задач, требующих строгой физико-химической релаксации, восстановленный остов следует рассматривать как начальную структуру для последующей короткой оптимизации, а не как замену силового поля.

Отдельные направления развития связаны с расширением метода на нестандартные и модифицированные нуклеотиды, увеличением входного контекста, учетом стерических столкновений и применением к построению начальных атомных моделей ДНК по данным крио-ЭМ. Возможна также замена генерации из чистого шума подходом, при котором восстановление начинается с уже имеющейся приближенной геометрии [22].

СПИСОК ЛИТЕРАТУРЫ

1. Marrink S. J. и др. The MARTINI Force Field: Coarse Grained Model for Biomolecular Simulations // J. Phys. Chem. B. 2007. T. 111, № 27. С. 7812–7824.
2. Darré L. и др. SIRAH: A Structurally Unbiased Coarse-Grained Force Field for Proteins with Aqueous Solvation and Long-Range Electrostatics // J. Chem. Theory Comput. 2015. T. 11, № 2. С. 723–739.
3. Lu X.-J. 3DNA: a software package for the analysis, rebuilding and visualization of three-dimensional nucleic acid structures // Nucleic Acids Res. 2003. T. 31, № 17. С. 5108–5121.
4. Lu X.-J., Bussemaker H. J., Olson W. K. DSSR: an integrated software tool for dissecting the spatial structure of RNA // Nucleic Acids Res. 2015. С. gkv716.
5. Васильев В. Мезомасштабное моделирование элементов хроматина методом Монте Карло: разработка и апробация модели: Выпускная квалификационная работа магистра. МГУ имени М.В. Ломоносова, 2025.

6. Berendsen H. J. C., Van Der Spoel D., Van Drunen R. GROMACS: A message-passing parallel molecular dynamics implementation // Comput. Phys. Commun. 1995. Т. 91, № 1–3. С. 43–56.
7. Weiner P. K., Kollman P. A. AMBER: Assisted model building with energy refinement. A general program for modeling molecules and their interactions // J. Comput. Chem. 1981. Т. 2, № 3. С. 287–303.
8. Brooks B. R. и др. CHARMM: A program for macromolecular energy, minimization, and dynamics calculations // J. Comput. Chem. 1983. Т. 4, № 2. С. 187–217.
9. Suder D. S., Gonen S. Mitigating the Blurring Effect of CryoEM Averaging on a Flexible and Highly Symmetric Protein Complex through Sub-Particle Reconstruction // Int. J. Mol. Sci. Multidisciplinary Digital Publishing Institute, 2024. Т. 25, № 11. С. 5665.
10. Keepers J. W. и др. Molecular mechanical studies of DNA flexibility: coupled backbone torsion angles and base-pair openings // Proc. Natl. Acad. Sci. U. S. A. 1982. Т. 79, № 18. С. 5537–5541.
11. О хрупкой ДНК и ее палатине • Библиотека [Электронный ресурс] // «Элементы». URL: https://elementy.ru/nauchno-populyarnaya_biblioteka/437224/O_khrupkoy_DNK_i_ee_paladine (дата обращения: 29.09.2025).
12. X3DNA-DSSR Homepage -- Nucleic Acid Structures [Электронный ресурс]. URL: <http://home.x3dna.org/highlights/torsion-angles-of-nucleic-acid-structures> (дата обращения: 17.05.2026).
13. Altona C., Sundaralingam M. Conformational analysis of the sugar ring in nucleosides and nucleotides. New description using the concept of pseudorotation // J. Am. Chem. Soc. 1972. Т. 94, № 23. С. 8205–8212.
14. Szabla R. и др. Excited-state hydrogen atom abstraction initiates the photochemistry of β -2'-deoxycytidine // Chem. Sci. 2015. Т. 6, № 3. С. 2035–2043.
15. Parsons J. и др. Practical conversion from torsion space to Cartesian space for *in silico* protein synthesis // J. Comput. Chem. 2005. Т. 26, № 10. С. 1063–1068.
16. Ho J., Jain A., Abbeel P. Denoising Diffusion Probabilistic Models. arXiv, 2020.
17. Song Y., Ermon S. Generative Modeling by Estimating Gradients of the Data Distribution. arXiv, 2019.
18. Song Y. и др. Score-Based Generative Modeling through Stochastic Differential Equations. arXiv, 2020.
19. Vaswani A. и др. Attention Is All You Need. arXiv, 2017.
20. Chen T., Zhang R., Hinton G. Analog Bits: Generating Discrete Data using Diffusion Models with Self-Conditioning. arXiv, 2022.
21. Loshchilov I., Hutter F. Decoupled Weight Decay Regularization: arXiv:1711.05101. arXiv, 2019.
22. Shi Y. и др. Diffusion Schrödinger Bridge Matching. arXiv, 2023.