


Применение глубокого обучения для восстановления структуры сахарофосфатного остова ДНК

Выполнил

Сидоров В. В.

Научный руководитель

к.ф.-м.н. Армеев Г. А.



Московский
государственный
университет
имени М. В. Ломоносова



БИОЛОГИЧЕСКИЙ ФАКУЛЬТЕТ
МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ М. В. ЛОМОНОСОВА




**Кафедра
Биоинженерии**
Биологического факультета МГУ



Введение. Структура ДНК

В контексте данной работы важны 2 части ДНК: **сахарофосфатный остов** и **азотистые основания**.




Введение. Мотивация

Существуют задачи, где не решена проблема преобразования некого огрубленного представления остова ДНК в полноатомное (решена для оснований)

Крупнозернистая молекулярная динамика ДНК проводится в огрубленном представлении

В крио-ЭМ особую сложность представляет создание корректной полноатомной модели, которая затем вписывается в электронную плотность



Цели и задачи

Цель

Разработать метод условной генерации сахарофосфатного остова ДНК при известных признаках азотистых оснований.


Задачи

1. Подготовить данные для обучения модели.
2. Спроектировать и реализовать нейросетевую модель.
3. Обучить разработанную модель восстанавливать структуру остова ДНК, опираясь на структуру оснований.
4. Оценить качество обученной модели.


Обзор литературы. Координаты нуклеотидов

Основания жесткие, поэтому их положение можно закодировать тройкой векторов. Остов подвижный, но приближенно почти вся подвижность находится в торсионных углах, значит закодировать можно ими.

Тройки векторов оснований



Торсионные углы остова





Обзор литературы. Генеративные модели

Для генерации объектов была использована обобщенная парадигма диффузии — модели, оценивающие ГЛПВ (градиент логарифма плотности вероятности) (score-based models, Song и др., 2019).

Распределение данных
(неизвестно)




Распределение модели




Глубокая нейронная сеть

Методы. Подготовка данных




Результаты. Архитектура модели

Из существующих в литературе компонентов был разработан уникальный диффузионный трансформер.




Результаты. Тренировка модели


Тренировка



Валидация




Тест



Среди K=4 лучший результат — 0,7 Å


Пример генерации




Результаты. Оценка качества по атомам

Фосфатные группы дают наибольший вклад в СКО модели. Это согласуется со структурой геометрического декодировщика: он начинает построение остова, начиная с гликозидной связи, и фосфаты накапливают все предыдущие ошибки построения.

СКО атомов геометрического декодировщика



Вклад ошибок атомов в СКО геометрического декодировщика



Результаты. Оценка геометрической корректности

СКО длин связей (Å)	СКО валентных углов (°)	Среднее число стерических конфликтов на 1000 атомов
0,1	14,6	70

По-видимому, ошибки в фосфатах критичны, и внутри этой группы сгенерированные атомы мешают друг другу.

Выводы

1. Подготовленный набор данных достаточен для обучения модели, а его применимость ограничена каноническими нуклеотидами и структурами двуцепочечной ДНК.
2. Разработанная модель позволяет генерировать геометрию остова ДНК, а ошибка модели во многом объясняется трудностью выбора верной моды из мультимодального распределения координат.
3. Координат оснований достаточно для восстановления геометрии остова ДНК, однако не достаточно для воспроизведения изначальных координат атомов в экспериментальных структурах.
4. Среднеквадратичное отклонение координат атомов от изначальной структуры не следует использовать для оценки качества генерации остова ДНК, поскольку эта метрика не отражает геометрическую корректность модели. Нужно сравнивать эталонные и восстановленные длины связей и валентные углы.


Приложение. Исходный код

Весь код для подготовки данных, тренировки и использования модели написан на Python 3 (библиотеки PyNAMod, PyTorch, Lightning). Исходный код и веса модели находятся в публичном доступе в GitHub репозитории:

<https://github.com/Eclipter/base2backbone>


Список структур, использованных для обучающей выборки зафиксирован в "thesis_2026-05-17.json".

Приложение. Пример генерации крайнего остова




Приложение. Пример генерации всего остова

Структура с
истинным
остовом



Структура со
сгенерированным
остовом




Приложение. Гиперпараметры модели

- Размерность скрытого пространства: 256
- Темп обучения: 10^{-3}
- Коэффициент L_2 -регуляризации: 10^{-2} .
- Размер пакета: 50000.
- Вес окон с крайними нуклеотидами: 0,3.
- 200 эпох обучения.
- Старт стохастического усреднения весов на эпохе 100.
- 200 шагов диффузии.
- Уровень шума для угловых компонент:
 - Минимальный: 0,01π.
 - Максимальный: π.
- Уровень шума для компоненты $\log(\tau_m)$:
 - Минимальный: 0,01.
 - Максимальный: 1,5.
- Вес ошибки по каналу $\log(\tau_m)$: 1.
- Вес дополнительного штрафа за геометрическое замыкание сахарофосфатного остова:
 - Общий: 10^{-3} .
 - Отдельные веса компонент функции потерь замыкания сахарного кольца:
 - Атомные связи: 1.
 - Валентные углы: 0,3.
 - Торсионные углы: 1.

Приложение. Лучший из K

Зависимость среднего СКО остова на лучшем запуске от числа запусков K



Приложение. Сравнение качества

Сравнение качества модели с контрольными методами: средним шаблоном, вариантами kNN и PHENIX на тестовом наборе данных

	Среднее	Медиана	90-й перцентиль	Среднее (внутренние нуклеотиды)	Среднее (крайние нуклеотиды)	Средний RMSD длин связей (Å)	Средний RMSD углов (°)	Среднее число стерических конфликтов на 1000 атомов
Нейросеть	1,0	0,9	1,8	0,9	1,3	0,10	14,6	70
Шаблонная реконстр.	1,0	0,9	1,5	1,0	1,3	0,04	9,9	31
kNN (только основания)	1,2	1,0	2,0	1,1	1,8	0,12	9,0	65
kNN (только начала систем отсчета)	0,8	0,7	1,4	0,7	1,1	0,10	7,1	60
kNN (только направления систем отсчета)	0,9	0,8	1,9	0,9	1,3	0,09	6,2	56
kNN (только системы отсчета)	0,7	0,5	1,3	0,6	1,0	0,10	8,1	59
kNN (системы отсчета и типы оснований)	0,7	0,5	1,3	0,7	1,1	0,9	6,3	58
kNN (системы отсчета комплем-ых нукл-ов)	1,0	0,8	1,9	0,9	1,3	0,1	6,9	63
kNN (все признаки)	0,7	0,6	1,5	0,7	1,1	0,1	6,4	61
PHENIX	1,1	0,9	2,2	1,1	1,6	0,01	0,6	4